

ESTIMATION



Il s'agit dans ce module de trouver une estimation par intervalle de confiance d'un paramètre θ , c'est-à-dire de construire une « fourchette de valeurs numériques permettant de situer » θ avec une probabilité $1 - \alpha$

$$1 - \alpha = \text{Prob}[\theta_1 < \theta < \theta_2]$$

La démarche comprend deux étapes :

- avant le tirage d'un échantillon de taille n , un estimateur $\hat{\theta}$ a été choisi et la loi de probabilité de $\hat{\theta}$ permet de construire un intervalle aléatoire noté $[g_1(\hat{\theta}), g_2(\hat{\theta})]$ susceptible de contenir la valeur du paramètre θ avec une probabilité $1 - \alpha$ fixée a priori ;
- après tirage, la valeur particulière t de $\hat{\theta}$ calculée à partir des données de l'échantillon permet de déterminer les bornes $g_1(t)$ et $g_2(t)$ de l'intervalle de confiance recherché.


S'il est possible de réécrire le système d'inégalités en isolant θ , on peut déterminer un intervalle dont les limites dépendent de $\hat{\theta}$ et tel que :

$$1 - \alpha = \text{Prob}[g_1(\hat{\theta}) < \theta < g_2(\hat{\theta})]$$

Ici, l'intervalle qui encadre θ est aléatoire et il possède la propriété de recouvrir la valeur θ dans $1 - \alpha$ des cas. La prise en compte d'un échantillon particulier, c'est-à-dire d'une valeur numérique particulière pour $\hat{\theta}$, et donc pour $g_1(\hat{\theta})$ et $g_2(\hat{\theta})$, permet d'obtenir une fourchette qui a de « grandes » chances de « contenir » la valeur inconnue θ si $1 - \alpha$ est élevé.

$$1 - \alpha = \text{Prob}[g_1(\hat{\theta}) < \theta < g_2(\hat{\theta})] = \text{Prob}[c_1 < \theta < c_2]$$

- $[c_1, c_2]$ ou $[g_1(\hat{\theta}), g_2(\hat{\theta})]$ est appelé intervalle de confiance,
- c_1, c_2 sont les limites de confiance,
- $1 - \alpha$: degré de confiance ou degré de certitude.



La probabilité α se répartit selon les cas soit à droite d'un certain seuil, soit à gauche, soit à droite et à gauche simultanément.

On parlera :

- d'intervalle bilatéral symétrique si : $\alpha_1 = \alpha_2 = \alpha / 2$
- d'intervalle bilatéral si $\alpha_1 \neq 0$ et $\alpha_2 \neq 0$ avec $\alpha_1 + \alpha_2 = \alpha$
- d'intervalle unilatéral à gauche si $\alpha_2 = 0$
- d'intervalle unilatéral à droite si $\alpha_1 = 0$

Estimation par intervalle de confiance de la moyenne d'une population lorsque la variance de la population est connue

Le problème est le suivant : il faut encadrer m (moyenne de la population).

C'est-à-dire on recherche m_1 et m_2 telles que :

$$\exists m_1, m_2 \in \mathbb{R} \text{ telles que } 1 - \alpha = \text{prob}[m_1 < m < m_2]$$

On suppose que X obéit à une loi normale $X \equiv N(m, \sigma)$ avec σ connu


On prélève un échantillon IID de taille n

On sait que $\bar{X} \equiv N\left(m, \frac{\sigma}{\sqrt{n}}\right)$ avec n la taille de l'échantillon (Cf module 1)

Si on forme la variable aléatoire normale centrée réduite $U = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}} \equiv N(0,1)$

Cas d'un intervalle bilatéral

Représentons graphiquement cette loi :



u_{α_1} et $u_{1-\alpha_2}$ sont des valeurs lues dans la table¹ de la loi normale centrée réduite.

A gauche de u_{α_1} nous avons une probabilité α_1 d'où u_{α_1} , à gauche de $u_{1-\alpha_2}$, on a une probabilité cumulée de $1-\alpha_2$ d'où $u_{1-\alpha_2}$

$$1 - \alpha = \text{Prob} \left[u_{\alpha_1} < \frac{\bar{X} - m}{\sigma / \sqrt{n}} < u_{1 - \alpha_2} \right]$$

$$1 - \alpha = \text{Prob} \left[u_{\alpha_1} \frac{\sigma}{\sqrt{n}} < \bar{X} - m < u_{1 - \alpha_2} \frac{\sigma}{\sqrt{n}} \right]$$


$$= \text{prob} \left[u_{\alpha_1} \frac{\sigma}{\sqrt{n}} - \bar{X} < -m < u_{1 - \alpha_2} \frac{\sigma}{\sqrt{n}} - \bar{X} \right]$$

$$= \text{Prob} \left[\underbrace{\bar{X} - u_{1 - \alpha_2} \frac{\sigma}{\sqrt{n}}}_{m_1} < m < \underbrace{\bar{X} - u_{\alpha_1} \frac{\sigma}{\sqrt{n}}}_{m_2} \right]$$

Cas particulier : intervalle bilatéral symétrique

Intervalle bilatéral symétrique si : $\alpha_1 = \alpha_2 = \alpha / 2$

Graphique 1



$$u_{\alpha/2} = -u_{1-\alpha/2}$$

$$1 - \alpha = \text{Prob} \left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < m < \bar{X} - u_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Comme $u_{1-\alpha/2} = -u_{\alpha/2}$ on peut écrire :

$$1 - \alpha = \text{Prob} \left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} < m < \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Ou encore :

$$1 - \alpha = \text{Prob} \left[\bar{X} + u_{\alpha/2} \frac{\sigma}{\sqrt{n}} < m < \bar{X} - u_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Ce qui revient à écrire :

$$1 - \alpha = \text{Prob} \left[m \in \left[\bar{X} \pm u_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \right] \text{ ou } 1 - \alpha = \text{Prob} \left[m \in \left[\bar{X} \pm u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \right]$$

On cherche un intervalle de degré de confiance bilatéral symétrique à 95% de la moyenne d'une population m . On sait que la variable aléatoire obéit à une loi normale dont l'écart type (connu) est 2 : $X \equiv N(m, 2)$. On prélève dans cette population un échantillon de taille $n=100$.

$$\bar{X} \equiv N\left(m, \frac{\sigma}{\sqrt{n}}\right)$$

$$\alpha_1 = \alpha_2 = \alpha / 2 = 2,5\% \text{ (intervalle bilatéral symétrique)}$$

$$u_{\alpha/2} = -1,96 \quad u_{1-\alpha/2} = 1,96$$

$$\begin{aligned} 95\% &= \text{Prob} \left[-1,96 < \frac{\bar{X} - m}{\sigma / \sqrt{n}} < 1,96 \right] \\ &= \text{Prob} \left[m \in \left[\bar{X} \pm u_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \right] \end{aligned}$$

Supposons que dans l'échantillon la moyenne soit égale à 10 : $\bar{X} = 10$

L'intervalle de confiance calculé est donc : (on le note : $IC_{.95}$)

$$IC_{.95} = [10 \pm 1,96 \frac{2}{\sqrt{100}}] = [9,61; 10,39]$$

Estimation par intervalle de confiance de la moyenne d'une population
lorsque la variance de la population est inconnue

Le problème est toujours le même : il faut encadrer m .

C'est-à-dire on recherche les m_1 et m_2 telles que :

$$\exists m_1, m_2 \in \mathbb{R} \text{ telles que } 1 - \alpha = \text{prob}[m_1 < m < m_2]$$

$X \equiv N(m, \sigma)$ par hypothèse mais ici σ est inconnu

$$\bar{X} \equiv N\left(m, \frac{\sigma}{\sqrt{n}}\right) \text{ avec } n \text{ la taille de l'échantillon}$$

Lorsque σ est inconnu, on utilise la loi de Student. (Cf module 1)


$$\frac{\bar{X} - m}{s / \sqrt{n-1}} \equiv T(n-1)$$

$$\frac{\bar{X} - m}{S / \sqrt{n-1}} = \frac{\bar{X} - m}{\hat{S} / \sqrt{n}} \equiv T(n-1) \text{ car } \hat{S}^2 = \frac{n}{n-1} S^2$$

avec : $\begin{cases} S : \text{estimateur biaisé de } \sigma \\ \hat{S} : \text{estimateur sans biais de } \sigma. \end{cases}$

Cas d'un intervalle bilatéral

Représentons graphiquement cette loi :



t_{α_1} et $t_{1-\alpha_2}$ sont des valeurs lues dans la table de Student. On met ici aussi en indice le seuil de probabilité correspondant à la fonction de répartition.

Ecrivons ce que représente graphiquement la probabilité $1 - \alpha$:

$$1 - \alpha = \text{Prob}[t_{\alpha_1} < T(n-1) < t_{1-\alpha_2}]$$

$$1 - \alpha = \text{Prob} \left[t_{\alpha_1} < \frac{\bar{X} - m}{S / \sqrt{n-1}} < t_{1-\alpha_2} \right]$$


$$= \text{Prob} \left[t_{\alpha_1} \frac{S}{\sqrt{n-1}} < \bar{X} - m < t_{1-\alpha_2} \frac{S}{\sqrt{n-1}} \right]$$

$$= \text{Prob} \left[-\bar{X} + t_{\alpha_1} \frac{S}{\sqrt{n-1}} < -m < t_{1-\alpha_2} \frac{S}{\sqrt{n-1}} - \bar{X} \right]$$

$$1 - \alpha = \text{Prob} \left[\underbrace{\bar{X} - t_{1-\alpha_2} \frac{S}{\sqrt{n-1}}}_{m_1} < m < \underbrace{\bar{X} - t_{\alpha_1} \frac{S}{\sqrt{n-1}}}_{m_2} \right]$$

Cas particulier : intervalle bilatéral symétrique

Graphique 2



$$1 - \alpha = \text{Prob} \left[m \in \left[\bar{X} \pm t_{1-\alpha/2} \frac{S}{\sqrt{n-1}} \right] \right]$$

$$\text{ou encore : } 1 - \alpha = \text{Prob} \left[m \in \left[\bar{X} \pm t_{\alpha/2} \frac{S}{\sqrt{n-1}} \right] \right]$$

Intervalle unilatéral à gauche

Dans ce cas, $\alpha_1 = \alpha$ et $\alpha_2 = 0$

$$\begin{aligned} 1 - \alpha &= \text{Prob} \left[\frac{\bar{X} - m}{S / \sqrt{n-1}} > t_{\alpha} \right] = \text{Prob} \left[m < \bar{X} - t_{\alpha} \frac{S}{\sqrt{n-1}} \right] \\ &= \text{Prob} \left[m < \underbrace{\bar{X} + t_{1-\alpha} \frac{S}{\sqrt{n-1}}}_{m_2} \right] \end{aligned}$$

Intervalle unilatéral à droite

Dans ce cas, $\alpha_1 = 0$ et $\alpha_2 = \alpha$

$$\begin{aligned} 1 - \alpha &= \text{Prob} \left[\frac{\bar{X} - m}{S / \sqrt{n-1}} < t_{1-\alpha} \right] \\ &= \text{Prob} \left[m > \underbrace{\bar{X} - t_{1-\alpha} \frac{S}{\sqrt{n-1}}}_{m_1} \right] \end{aligned}$$

Estimation par intervalle de confiance de la variance d'une population

Par hypothèse, X obéit toujours à une loi normale : $X \equiv N(m, \sigma)$


Le problème est le suivant : il faut encadrer σ , l'écart-type de la population qui est inconnu. On recherche donc deux valeurs σ_1^2 et σ_2^2 encadrant σ^2

$$\exists \sigma_1^2, \sigma_2^2 \in \mathbb{R} / 1 - \alpha = \text{prob}[\sigma_1^2 < \sigma^2 < \sigma_2^2]$$

On sait que : $\frac{nS^2}{\sigma^2} \equiv \chi^2(n-1)$ avec n la taille de l'échantillon. (Cf module 1)

Cas d'un intervalle bilatéral

Représentons graphiquement cette loi :



$\chi_{\alpha_1}^2$ et $\chi_{1-\alpha_2}^2$ sont deux valeurs lues dans la table de la loi du χ^2 . On met ici aussi en indice la probabilité correspondant à la fonction de répartition

$$1 - \alpha = \text{Prob} \left[\chi_{\alpha_1}^2 < \chi^2(n-1) < \chi_{1-\alpha_2}^2 \right]$$

Remplaçons $\chi^2(n-1)$ par son expression :


$$1 - \alpha = \text{Prob} \left[\chi_{\alpha_1}^2 < \frac{nS^2}{\sigma^2} < \chi_{1-\alpha_2}^2 \right]$$

$$= \text{Prob} \left[\frac{\chi_{\alpha_1}^2}{nS^2} < \frac{1}{\sigma^2} < \frac{\chi_{1-\alpha_2}^2}{nS^2} \right]$$

$$= \text{Prob} \left[\frac{nS^2}{\chi_{\alpha_1}^2} > \sigma^2 > \frac{nS^2}{\chi_{1-\alpha_2}^2} \right]$$

$$1 - \alpha = \text{Prob} \left[\frac{nS^2}{\chi_{1-\alpha_2}^2} < \sigma^2 < \frac{nS^2}{\chi_{\alpha_1}^2} \right]$$

Cas particulier : intervalle bilatéral symétrique



$$1 - \alpha = \Pr \text{ ob } \left[\frac{nS^2}{\chi^2_{1-\alpha/2}} < \sigma^2 < \frac{nS^2}{\chi^2_{\alpha/2}} \right]$$

intervalle unilatéral à gauche

$$\begin{aligned} 1 - \alpha &= \text{Prob} \left[\frac{nS^2}{\sigma^2} > \chi_{\alpha}^2 \right] = \text{Prob} \left[\frac{nS^2}{\chi_{\alpha}^2} > \sigma^2 \right] \\ &= \text{Prob} \left[\sigma^2 < \frac{nS^2}{\chi_{\alpha}^2} \right] \end{aligned}$$

intervalle unilatéral à droite

$$\begin{aligned} 1 - \alpha &= \text{Prob} \left[\frac{nS^2}{\sigma^2} < \chi_{1-\alpha}^2 \right] = \text{Prob} \left[\frac{nS^2}{\chi_{1-\alpha}^2} < \sigma^2 \right] \\ &= \text{Prob} \left[\sigma^2 > \frac{nS^2}{\chi_{1-\alpha}^2} \right] \end{aligned}$$

L'énoncé

Un directeur d'école veut connaître la taille moyenne de ses 1 000 élèves. Il mesure un échantillon de **100 élèves** choisis au hasard.

- **Moyenne de l'échantillon ($\bar{x}$)** : 170 cm
- **Écart-type de l'échantillon (s)** : 10 cm
- **Taille de l'échantillon (n)** : 100
- **Niveau de confiance souhaité** : 95 % (ce qui correspond à une valeur critique $z = 1,96$)

La formule de l'intervalle de confiance (IC) est :

$$IC = \bar{x} \pm z \times \frac{s}{\sqrt{n}}$$

1. **Calcul de l'erreur standard :** $\frac{10}{\sqrt{100}} = \frac{10}{10} = 1$

2. **Calcul de la marge d'erreur :** $1,96 \times 1 = 1,96$

3. **Calcul des bornes :**

1. Borne inférieure : $170 - 1,96 = 168,04$

2. Borne supérieure : $170 + 1,96 = 171,96$

Ce que cela signifie :

On est confiant à 95 % que la **vraie taille moyenne** de l'ensemble des 1 000 élèves de l'école se situe entre environ 168 cm et 172 cm. Si on recommençait l'expérience avec 100 autres élèves, l'intervalle changerait légèrement, mais 95 % de ces intervalles contiendraient la vraie moyenne.

Un chocolatier veut vérifier le poids moyen de ses tablettes "100g". Il pèse un petit échantillon de **9 tablettes** et obtient :

- **Moyenne de l'échantillon ($\bar{x}$)** : 102 g
- **Écart-type de l'échantillon (s)** : 3 g
- **Taille de l'échantillon (n)** : 9
- **Niveau de confiance** : 95 %

La formule devient : $IC = \bar{x} \pm t \times \frac{s}{\sqrt{n}}$

1. **Trouver la valeur de t** : On cherche dans la table de Student avec $n - 1$ degrés de liberté (ddl). Ici, $ddl = 9 - 1 = 8$. Pour un risque $\alpha = 5\%$, la table donne $t = 2,306$.

2. **Calcul de l'erreur standard** : $\frac{s}{\sqrt{n}} = \frac{3}{\sqrt{9}} = \frac{3}{3} = 1$

3. **Calcul de la marge d'erreur** : $2,306 \times 1 = 2,306$

4. **Calcul des bornes** :

1. Borne inférieure : $102 - 2,306 = 99,694$

2. Borne supérieure : $102 + 2,306 = 104,306$

Ce que cela signifie :

Bien que la moyenne de l'échantillon soit de 102 g, il existe une probabilité de 95 % que le poids moyen réel de toute la production de tablettes se situe entre **99,69 g** et **104,31 g**. Comme 100 g est inclus dans cet intervalle, le chocolatier peut estimer que sa production est conforme.

Un laboratoire teste la précision d'une balance de précision en pesant **10 fois** un poids standard de 50g. Il observe une dispersion (variance) dans les mesures.

- **Taille de l'échantillon (n)** : 10
- **Variance de l'échantillon (s^2)** : $0,04 \text{ g}^2$
- **Niveau de confiance** : 95 % ($\alpha = 0,05$)

La formule de l'intervalle de confiance pour la variance est :

$$IC = \left[\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}} ; \frac{(n-1)s^2}{\chi^2_{\alpha/2}} \right]$$

1. Degrés de liberté (ddl) : $n - 1 = 10 - 1 = 9$

2. Valeurs critiques du χ^2 (lues dans la table du Khi-deux) :

1. Pour $\alpha/2 = 0,025$ et $ddl = 9$: $\chi^2_{0,975} = \mathbf{19,02}$ (borne droite de la table)

2. Pour $1 - \alpha/2 = 0,975$ et $ddl = 9$: $\chi^2_{0,025} = \mathbf{2,70}$ (borne gauche de la table)

3. Calcul du numérateur : $(n-1)s^2 = 9 \times 0,04 = 0,36$

4. Calcul des bornes :

1. Borne inférieure : $0,36/19,02 \approx \mathbf{0,0189}$

2. Borne supérieure : $0,36/2,70 \approx \mathbf{0,1333}$

```
import numpy as np
from scipy import stats

# Données de l'exemple (poids des tablettes de chocolat)
donnees = np.array([101, 103, 102, 105, 98, 100, 104, 102, 103])
n = len(donnees)
moyenne = np.mean(donnees)
sem = stats.sem(donnees) # Erreur standard de la moyenne ( $s / \sqrt{n}$ )

# Calcul de l'intervalle à 95%
intervalle = stats.t.interval(confidence=0.95, df=n-1, loc=moyenne, scale=sem)

print(f"Moyenne : {moyenne}")
print(f"Intervalle de confiance (95%) : {intervalle}")
```



```
import numpy as np
from scipy.stats import chi2

# Données de l'exemple de la balance
n = 10
variance_obs = 0.04
ddl = n - 1
alpha = 0.05

# Valeurs critiques du Khi-deux
chi2_low = chi2.ppf(alpha / 2, ddl)
chi2_high = chi2.ppf(1 - alpha / 2, ddl)

# Calcul des bornes
ic_inf = (ddl * variance_obs) / chi2_high
ic_sup = (ddl * variance_obs) / chi2_low
```

En statistique et dans les bibliothèques Python (comme `scipy.stats`), **PPF** signifie **Percent Point Function**.

C'est l'équivalent de la **fonction quantile** ou de la **réciroque de la fonction de répartition (CDF)**.

À quoi ça sert ?

Alors que la fonction classique (CDF) vous donne la probabilité pour une valeur donnée, la fonction **PPF** fait l'inverse :

- **Entrée** : Une probabilité (q).
- **Sortie** : La valeur (x) telle que la probabilité d'être inférieur ou égal à x est égale à q

