

Nom et Prénom : EZZEROUALY Aicha Groupe : 02 Filière : SINFO S6 N°Apogée : 2334389

RAPPORT DE TP 7

Estimation par Intervalle de Confiance

Analyse des outils Python utilisés dans deux programmes statistiques

Matière	Statistiques Inférentielles
Librairies	NumPy / SciPy
Thème	Intervalles de confiance (moyenne & variance)
Niveau de confiance	95% ($\alpha = 0,05$)

Introduction

Ce rapport présente une analyse détaillée de deux programmes Python permettant de calculer des intervalles de confiance, conformément au cours sur l'estimation statistique. Ces programmes exploitent les bibliothèques NumPy et SciPy, outils incontournables du calcul scientifique en Python.

Le premier programme traite l'estimation de la moyenne d'une population lorsque la variance est inconnue (loi de Student), et le second traite l'estimation de la variance d'une population (loi du Khi-deux).

Programme 1 — Estimation de la Moyenne (Loi de Student)

1.1 Code source

Ce programme calcule l'intervalle de confiance à 95% de la moyenne d'un échantillon de poids de tablettes de chocolat, en utilisant la loi de Student (σ inconnu).

```
import numpy as np
from scipy import stats

# Données de l'exemple (poids des tablettes de chocolat)
donnees = np.array([101, 103, 102, 105, 98, 100, 104, 102, 103])
n = len(donnees)
moyenne = np.mean(donnees)
sem = stats.sem(donnees) # Erreur standard de la moyenne (s / sqrt(n))

# Calcul de l'intervalle à 95%
intervalle = stats.t.interval(confidence=0.95, df=n-1, loc=moyenne,
                              scale=sem)

print(f"Moyenne : {moyenne}")
```

```
|print(f"Intervalle de confiance (95%) : {intervalle}")
```

1.2 Détail de chaque outil

import numpy as np

NumPy (Numerical Python) est la bibliothèque fondamentale pour le calcul numérique en Python. Elle fournit des tableaux (arrays) multidimensionnels et des fonctions mathématiques optimisées.

np.array([...])

Crée un tableau NumPy à partir d'une liste Python. Contrairement aux listes, les arrays NumPy permettent des opérations vectorisées (addition, multiplication, calcul statistique) directement sur l'ensemble des données sans boucle.

len(donnees) — taille de l'échantillon n

La fonction Python standard len() renvoie le nombre d'éléments dans le tableau. Ici, $n = 9$ (9 tablettes mesurées), soit les degrés de liberté : $ddl = n - 1 = 8$.

np.mean(donnees) — Calcul de la moyenne

Calcule la moyenne arithmétique de l'échantillon : $\bar{x} = (\sum x_i) / n$. C'est l'estimateur ponctuel de la moyenne de la population m . Résultat ici : $\bar{x} = 102$ g.

stats.sem(donnees) — Erreur standard de la moyenne

SEM = Standard Error of the Mean. Calcule l'erreur standard : $sem = s / \sqrt{n}$, où s est l'écart-type de l'échantillon. C'est la mesure de la dispersion de la moyenne échantillonnale autour de la vraie moyenne.

- $sem = s / \sqrt{n} = 3 / \sqrt{9} = 1$
- Plus sem est petit, plus l'estimation est précise

stats.t.interval() — Calcul de l'intervalle de confiance (loi de Student)

C'est la fonction principale du programme. Elle retourne directement les bornes inférieure et supérieure de l'intervalle de confiance selon la loi de Student $T(n-1)$.

Paramètre	Valeur utilisée	Signification
confidence	0.95	Niveau de confiance $1 - \alpha = 95\%$
df	$n - 1$	Degrés de liberté $= 9 - 1 = 8$
loc	moyenne	Centre de l'intervalle $= \bar{x} = 102$ g
scale	sem	Dispersion = erreur standard = 1

Formule mathématique appliquée : $IC = [\bar{x} \pm t_{\{1-\alpha/2\}} \times s/\sqrt{n}] = [102 \pm 2,306 \times 1] = [99,694 ; 104,306]$

1.3 Résultat et interprétation

Grandeur	Valeur
Taille de l'échantillon n	9

Moyenne $\bar{x}$	102 g
Écart-type s	3 g
Erreur standard (sem)	1 g
Degrés de liberté (ddl)	8
t critique ($\alpha/2 = 2,5\%$)	2,306
Borne inférieure	99,694 g
Borne supérieure	104,306 g

Interprétation : On est confiant à 95% que le poids moyen réel de toutes les tablettes de la production se situe entre 99,69 g et 104,31 g. Comme 100 g est inclus dans cet intervalle, la production peut être considérée comme conforme.

Programme 2 — Estimation de la Variance (Loi du Khi-deux)

2.1 Code source

Ce programme calcule l'intervalle de confiance à 95% de la variance d'une population, en se basant sur la loi du Khi-deux $\chi^2(n-1)$. L'exemple traite d'une balance de précision.

```
import numpy as np
from scipy.stats import chi2

# Données de l'exemple de la balance
n = 10
variance_obs = 0.04
ddl = n - 1
alpha = 0.05

# Valeurs critiques du Khi-deux
chi2_low = chi2.ppf(alpha / 2, ddl)
chi2_high = chi2.ppf(1 - alpha / 2, ddl)

# Calcul des bornes
ic_inf = (ddl * variance_obs) / chi2_high
ic_sup = (ddl * variance_obs) / chi2_low
```

2.2 Détail de chaque outil

from scipy.stats import chi2

Importe uniquement l'objet `chi2` depuis `scipy.stats`. Cet objet représente la distribution du Khi-deux, utilisée pour construire des intervalles de confiance sur la variance d'une population normale.

Variables d'entrée

Variable	Valeur	Rôle statistique
n	10	Taille de l'échantillon
variance_obs	0.04 g ²	Variance observée dans l'échantillon (S ²)
ddl = n - 1	9	Degrés de liberté
alpha	0.05	Risque d'erreur α (niveau de confiance = 95%)

chi2.ppf() — Percent Point Function (Fonction quantile)

C'est l'outil central du programme. La PPF est l'inverse de la fonction de répartition (CDF) : elle prend en entrée une probabilité q et retourne la valeur x telle que $P(\chi^2 \leq x) = q$.

Appel	Probabilité q	Résultat χ^2	Rôle
chi2.ppf(alpha/2, ddl)	0.025	$\chi^2_{0.025} = 2,70$	Borne gauche (queue gauche)
chi2.ppf(1-alpha/2, ddl)	0.975	$\chi^2_{0.975} = 19,02$	Borne droite (queue droite)

Remarque : Contrairement à la loi normale qui est symétrique, la loi du Khi-deux est asymétrique (toujours positive). Les deux valeurs critiques sont donc différentes en valeur absolue.

Calcul des bornes de l'intervalle de confiance

La formule mathématique appliquée pour l'IC sur la variance est :

```
IC = [ (n-1) * S2 /  $\chi^2_{1-\alpha/2}$  ; (n-1) * S2 /  $\chi^2_{\alpha/2}$  ]

ic_inf = (ddl * variance_obs) / chi2_high -> (9 * 0,04) / 19,02 ≈ 0,0189
ic_sup = (ddl * variance_obs) / chi2_low -> (9 * 0,04) / 2,70 ≈ 0,1333
```

Attention : chi2_high (grande valeur) donne la borne INFérieure, et chi2_low (petite valeur) donne la borne SUPérieure, car les χ^2 sont au dénominateur (division inverse).

2.3 Résultat et interprétation

Grandeur	Valeur
Taille de l'échantillon n	10
Variance observée S ²	0,04 g ²
Degrés de liberté (ddl)	9
$\chi^2_{0,025}$ (borne gauche)	2,70
$\chi^2_{0,975}$ (borne droite)	19,02
Borne inférieure de σ^2	≈ 0,0189 g ²
Borne supérieure de σ^2	≈ 0,1333 g ²

Interprétation : On est confiant à 95% que la vraie variance des mesures de la balance se situe entre 0,0189 g² et 0,1333 g². Cet intervalle permet d'évaluer la précision réelle de la balance.

Comparaison des deux programmes

Critère	Programme 1 (Moyenne)	Programme 2 (Variance)
Paramètre estimé	Moyenne m (inconnue)	Variance σ^2 (inconnue)
Loi utilisée	Student $T(n-1)$	Khi-deux $\chi^2(n-1)$
Librairie clé	<code>scipy.stats (stats)</code>	<code>scipy.stats.chi2</code>
Fonction critique	<code>stats.t.interval()</code>	<code>chi2.ppf()</code>
Hypothèse sur X	X suit $N(m, \sigma)$ — σ inconnu	X suit $N(m, \sigma)$
Symétrie de la loi	Oui — IC centré en $\bar{x}$	Non — IC asymétrique
Paramètre de localisation	$\text{loc} = \bar{x}$ (moyenne)	Non applicable
Paramètre d'échelle	$\text{scale} = \text{sem} = s/\sqrt{n}$	Non applicable
Résultat produit	IC sur la moyenne	IC sur la variance

Conclusion

Ces deux programmes illustrent parfaitement comment Python, via les librairies NumPy et SciPy, permet de réaliser des calculs statistiques rigoureux en quelques lignes de code.

Le premier programme utilise `stats.t.interval()` qui encapsule entièrement le calcul de l'intervalle de confiance sur la moyenne via la loi de Student, en fournissant directement les bornes.

Le second programme adopte une approche plus manuelle en utilisant `chi2.ppf()` pour lire les quantiles de la loi du Khi-deux, puis en appliquant la formule théorique pour obtenir les bornes de l'IC sur la variance.

Dans les deux cas, les résultats obtenus par Python sont cohérents avec ceux calculés à la main à partir des tables statistiques, ce qui confirme la validité des deux approches.