
TP6 : Test ANOVA

Analyse de Variance (One-Way & Two-Way)

Realisé par :

Ismail FADYL

Apogée : 2333962

SINF // Gr02

Année universitaire : 2025–2026

1 Rappel théorique

L'ANOVA (ANalysis Of VAriance) repose sur la décomposition de la variabilité totale en deux sources :

$$\underbrace{\sum_{j=1}^p \sum_{i=1}^{n_j} (x_{ij} - \bar{x})^2}_{\text{SCT}} = \underbrace{\sum_{j=1}^p n_j (\bar{x}_j - \bar{x})^2}_{\text{SCE}} + \underbrace{\sum_{j=1}^p \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2}_{\text{SCR}} \quad (1)$$

où :

- $\bar{x} = \frac{1}{n} \sum_{j=1}^p n_j \bar{x}_j$ (moyenne globale)
- $\bar{x}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} x_{ij}$ (moyenne conditionnelle du groupe j)
- **SCT** : Somme des Carrés Totaux – variabilité totale des observations
- **SCE** : Somme des Carrés Expliqués – variabilité expliquée par le facteur
- **SCR** : Somme des Carrés Résiduels – variabilité résiduelle (non expliquée)

La statistique de test suit une loi de Fischer :

$$F = \frac{CME}{CMR} = \frac{SCE/(p-1)}{SCR/(n-p)} \sim \mathcal{F}(p-1, n-p) \quad (2)$$

Règle de décision : Si la p -value $< \alpha = 0,05$, on rejette H_0 et conclut à une différence significative entre les moyennes des groupes.

2 Exercice 1 – Calcul explicite de SCT, SCE, SCR

2.1 Données

Forêt 1	Forêt 2	Forêt 3
23,3	18,9	22,5
24,4	21,1	22,9
24,6	21,1	23,7
24,9	22,1	24,0
25,0	22,5	24,0
26,2	23,5	24,5

2.2 Code Python

Ce code applique directement les formules mathématiques vues en cours, sans utiliser de fonctions statistiques complexes.

Listing 1: Calcul de SCT, SCE, SCR avec NumPy

```

1 import numpy as np
2
3 # 1. Definition des echantillons (groupes)
4 foret1 = np.array([23.3, 24.4, 24.6, 24.9, 25.0, 26.2])
5 foret2 = np.array([18.9, 21.1, 21.1, 22.1, 22.5, 23.5])
6 foret3 = np.array([22.5, 22.9, 23.7, 24.0, 24.0, 24.5])
7
8 # 2. Moyenne globale de toutes les observations
9 toutes_donnees = np.concatenate([foret1, foret2, foret3])
10 x_bar = np.mean(toutes_donnees)
11
12 # 3. Moyennes et effectifs de chaque groupe
13 moy_f1, moy_f2, moy_f3 = np.mean(foret1), np.mean(foret2), np.mean(
14     foret3)
15 n1, n2, n3 = len(foret1), len(foret2), len(foret3)
16
17 # 4. SCT : ecarts a la moyenne globale
18 SCT = np.sum((toutes_donnees - x_bar)**2)
19
20 # 5. SCE : ecarts entre les groupes
21 SCE = (n1*(moy_f1 - x_bar)**2
22     + n2*(moy_f2 - x_bar)**2
23     + n3*(moy_f3 - x_bar)**2)
24
25 # 6. SCR : ecarts a l'interieur de chaque groupe
26 SCR = (np.sum((foret1 - moy_f1)**2)
27     + np.sum((foret2 - moy_f2)**2)
28     + np.sum((foret3 - moy_f3)**2))
29
30 print("=== Resultats ===")
31 print(f"Moyenne globale : {x_bar:.4f}")
32 print(f"Moy. Foret 1/2/3 : {moy_f1:.4f} / {moy_f2:.4f} / {moy_f3:.4f}")
33 print(f"SCT = {SCT:.4f}")
34 print(f"SCE = {SCE:.4f}")
35 print(f"SCR = {SCR:.4f}")
36 print(f"Verification SCE + SCR = {SCE + SCR:.4f} (doit etre = SCT)")

```

2.3 Résultats

Listing 2: Sortie console – Exercice 1

```

=== Resultats ===
Moyenne globale : 23.2889
Moy. Foret 1/2/3 : 24.7333 / 21.5333 / 23.6000
SCT = 51.2978
SCE = 31.5911
SCR = 19.7067
Verification SCE + SCR = 51.2978 (doit etre = SCT)

```

3 Exercice 2 – Généralisation avec une fonction et une boucle

3.1 Code Python

Pour traiter plusieurs facteurs facilement, on crée une fonction réutilisable qui boucle sur les groupes.

Listing 3: Fonction d'analyse de variance manuelle

```
1 import numpy as np
2 import pandas as pd
3
4 # Definition du dataset
5 data = {
6     'Engrais': ['A','A','A','A', 'B','B','B','B', 'C','C','C','C'],
7     'Eau':     ['Faible','Moyen','Fort','Max',
8                 'Faible','Moyen','Fort','Max',
9                 'Faible','Moyen','Fort','Max'],
10    'Rendement': [12.5, 14.2, 18.1, 20.5,
11                  13.1, 15.8, 19.5, 22.0,
12                  11.8, 13.9, 17.2, 19.8]
13 }
14 df = pd.DataFrame(data)
15
16 def calculer_anova_manuel(df, nom_facteur, nom_reponse):
17     """Calcule SCT, SCE et SCR pour un facteur donne."""
18     x_bar = df[nom_reponse].mean() # moyenne globale
19     SCT = np.sum((df[nom_reponse] - x_bar)**2)
20     SCE = 0.0
21     SCR = 0.0
22
23     for g in df[nom_facteur].unique():
24         donnees_g = df[df[nom_facteur] == g][nom_reponse]
25         n_g = len(donnees_g)
26         moy_g = donnees_g.mean()
27         SCE += n_g * (moy_g - x_bar)**2 # ecart entre groupes
28         SCR += np.sum((donnees_g - moy_g)**2) # ecart intra-groupe
29
30     return SCT, SCE, SCR
31
32 # --- Couple (Engrais, Rendement) ---
33 sct_e, sce_e, scr_e = calculer_anova_manuel(df, 'Engrais', 'Rendement')
34 print("--- Facteur ENGRAIS ---")
35 print(f"SCT: {sct_e:.4f} | SCE: {sce_e:.4f} | SCR: {scr_e:.4f}")
36
37 # --- Couple (Eau, Rendement) ---
38 sct_eau, sce_eau, scr_eau = calculer_anova_manuel(df, 'Eau', 'Rendement')
39 print("\n--- Facteur EAU ---")
40 print(f"SCT: {sct_eau:.4f} | SCE: {sce_eau:.4f} | SCR: {scr_eau:.4f}")
```

3.2 Résultats

Listing 4: Sortie console – Exercice 2

```
--- Facteur ENGRAIS ---
SCT: 131.3667 | SCE: 7.6717 | SCR: 123.6950

--- Facteur EAU ---
SCT: 131.3667 | SCE: 123.2200 | SCR: 8.1467
```

4 Exercice 3 – Vérification via les bibliothèques Python

En pratique, on utilise des outils dédiés comme `scipy` ou `statsmodels` pour réaliser ces calculs automatiquement et vérifier les résultats obtenus manuellement.

Listing 5: ANOVA One-Way et Two-Way automatiques

```
1 import pandas as pd
2 from scipy.stats import f_oneway
3 import statsmodels.api as sm
4 from statsmodels.formula.api import ols
5
6 # Definition du dataset
7 data = {
8     'Engrais': ['A','A','A','A', 'B','B','B','B', 'C','C','C','C'],
9     'Eau':      ['Faible','Moyen','Fort','Max',
10                 'Faible','Moyen','Fort','Max',
11                 'Faible','Moyen','Fort','Max'],
12     'Rendement': [12.5, 14.2, 18.1, 20.5,
13                  13.1, 15.8, 19.5, 22.0,
14                  11.8, 13.9, 17.2, 19.8]
15 }
16 df = pd.DataFrame(data)
17
18 # --- ONE-WAY ANOVA (facteur Engrais uniquement) ---
19 rendement_A = df[df['Engrais'] == 'A']['Rendement']
20 rendement_B = df[df['Engrais'] == 'B']['Rendement']
21 rendement_C = df[df['Engrais'] == 'C']['Rendement']
22
23 f_stat, pval = f_oneway(rendement_A, rendement_B, rendement_C)
24 print(f"ANOVA 1 facteur (Engrais) : F = {f_stat:.4f}, p-value = {pval:.4f}")
25
26 # --- TWO-WAY ANOVA (Engrais + Eau, sans interaction) ---
27 modele = ols('Rendement ~ C(Engrais) + C(Eau)', data=df).fit()
28 tableau_anova = sm.stats.anova_lm(modele, typ=2)
29
30 print("\n--- Tableau Two-Way ANOVA ---")
31 print(tableau_anova)
```

4.1 Résultats

Listing 6: Sortie console – Exercice 3

```
ANOVA 1 facteur (Engrais) : F = 0.2791, p-value = 0.7628

--- Tableau Two-Way ANOVA ---
```

	sum_sq	df	F	PR(>F)
C(Engrais)	7.671667	2.0	48.452632	1.982170e-04
C(Eau)	123.220000	3.0	518.821053	1.236933e-07
Residual	0.475000	6.0	NaN	NaN

4.2 Interprétation des résultats

Règles de décision basées sur la **p-value** avec un seuil $\alpha = 0,05$:

- **One-Way ANOVA (Engrais seul)** : $p = 0,79 > 0,05$. Pris isolément, le type d'engrais n'a **pas** d'effet significatif sur le rendement.
- **Two-Way ANOVA – Engrais** : $p = 0,000198 < 0,05$. L'effet de l'engrais devient **très significatif** une fois la variable Eau prise en compte : le modèle Two-Way est donc nettement plus informatif.
- **Two-Way ANOVA – Eau** : $p = 1,24 \times 10^{-7} \ll 0,05$. La quantité d'eau a un effet **extrêmement significatif** sur le rendement.
- **Interaction Engrais $\times$ Eau** : Non testable ici, car nous n'avons qu'une seule observation par combinaison (pas de répétitions) ; c'est pourquoi le modèle utilise + et non *.

*La formule clé à retenir : **SCT = SCE + SCR** et $p\text{-value} < 0,05 \Rightarrow$ on rejette H_0 !*