

Rapport

Encadre par :

Pr. Ahmed oirrak ahmed

Réalisé par : KAZBANE Meriem

G137298714

Statatstique et analyse de donnée

Filière et Niveau: SINFO – S5

Année universitaire : 2026 - 2027

Statistique et analyse de donnée

Dans ce TP, nous avons travaillé sur l'analyse de données qualitatives à partir d'un ensemble de produits décrits par plusieurs variables (Couleur, Poids et Forme).

Nous avons d'abord construit le tableau disjonctif complet, qui transforme les modalités en variables binaires (0/1). Ensuite, nous avons calculé le tableau de Burt, obtenu par le produit de la matrice disjonctive par sa transposée, afin d'analyser les relations entre les différentes modalités.

Enfin, nous avons vérifié un tableau de contingence pour étudier la relation entre deux variables et confirmer la cohérence des résultats.

Ce travail permet de mieux comprendre la représentation matricielle des données qualitatives et son importance dans l'analyse statistique multivariée.


Partie 1 :

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import randint

pas=8/80
x0 = -4
x1 = 4
x = np.arange(x0, x1, pas)
f = 1/np.sqrt(2*np.pi) * np.exp(-x**2/2)
plt.subplot(2, 2, 1)
plt.plot(x, f, label="N(0,1)")
plt.title("la loi normale standard")

plt.subplot(2, 2, 2)
plt.plot(x, f, label="N(0,2)")
plt.title("la loi normale standard")

plt.subplot(2, 2, 3)
plt.plot(x, f, label="N(0,4)")
plt.title("la loi normale standard")
```



Dans cette partie, nous avons étudié la loi normale, une loi de probabilité continue largement utilisée en statistique. Nous avons analysé ses paramètres principaux, la moyenne (μ) et l'écart-type (σ), ainsi que ses propriétés comme la symétrie et la forme en cloche. Cette étude nous permet de comprendre comment modéliser des phénomènes réels et calculer des probabilités pour des variables continues.

Partie 2 :

Calculer le tableau disjonctif

Le tableau de Burt

Vérifier le tableau de contingence

Produit	Couleur	Poids	Forme
P1	Bleu	Lourd	Rond
P2	Blanc	Léger	Carré
P3	Vert	Léger	Rond
P4	Bleu	Très lourd	Carré
P5	Blanc	Léger	Rond
P6	Vert	Très lourd	Carré
P7	Bleu	Léger	Rond
P8	Blanc	Très lourd	Carré
P9	Vert	Très lourd	Rond
P10	Bleu	Lourd	Carré

```
import pandas as pd
import numpy as np

produits = ["P1", "P2", "P3", "P4", "P5", "P6", "P7", "P8", "P9", "P10"]
couleur = ["Bleu", "Blanc", "Vert", "Bleu", "Blanc", "Vert", "Bleu", "Blanc", "Vert", "Bleu"]
poids = ["Lourd", "Léger", "Léger", "Très lourd", "Léger", "Très lourd", "Léger", "Très lourd", "Très lourd", "Lourd"]
forme = ["Rond", "Carré", "Rond", "Carré", "Rond", "Carré", "Rond", "Carré", "Rond", "Carré"]

# Modalités
modalites = {
    "Couleur": ["Bleu", "Blanc", "Vert"],
    "Poids": ["Léger", "Lourd", "Très lourd"],
    "Forme": ["Rond", "Carré"]
}

colonnes = modalites["Couleur"] + modalites["Poids"] + modalites["Forme"]

# Tableau disjonctif
T = []

for i in range(len(produits)):
```

```

for i in range(len(produits)):
    ligne = []

    # Couleur
    for c in modalites["Couleur"]:
        if couleur[i] == c:
            ligne.append(1)
        else:
            ligne.append(0)

    # Poids
    for p in modalites["Poids"]:
        if poids[i] == p:
            ligne.append(1)
        else:
            ligne.append(0)

    # Forme
    for f in modalites["Forme"]:
        if forme[i] == f:
            ligne.append(1)
        else:
            ligne.append(0)

    T.append(ligne)

```

```
df_disjonctif = pd.DataFrame(T, columns=colonnes, index=produits)
```

```

print("=== Tableau disjonctif complet ===")
print(df_disjonctif)

```

```
#Tableau de Burt (avec boucles)
```

```

n = len(colonnes)
burt = np.zeros((n, n))

```

```

for i in range(n):
    for j in range(n):
        somme = 0
        for k in range(len(T)):
            somme += T[k][i] * T[k][j]
        burt[i][j] = somme

```

```
df_burt = pd.DataFrame(burt, index=colonnes, columns=colonnes)
```

```

print("\n=== Tableau de Burt ===")
print(df_burt)

```

```
# Tableau de contingence Poids x Forme (avec boucles)
```

```
contingence = {}

for p in modalites["Poids"]:
    contingence[p] = {}
    for f in modalites["Forme"]:
        count = 0
        for i in range(len(produits)):
            if poids[i] == p and forme[i] == f:
                count += 1
        contingence[p][f] = count

df_contingence = pd.DataFrame(contingence).T

print("\n=== Tableau de contingence (Poids x Forme) ===")
print(df_contingence)

print("\nSomme totale =", df_contingence.values.sum())
```

```
=== Tableau disjonctif complet ===
```

	Bleu	Blanc	Vert	Léger	Lourd	Très lourd	Rond	Carré
P1	1	0	0	0	1	0	1	0
P2	0	1	0	1	0	0	0	1
P3	0	0	1	1	0	0	1	0
P4	1	0	0	0	0	1	0	1
P5	0	1	0	1	0	0	1	0
P6	0	0	1	0	0	1	0	1
P7	1	0	0	1	0	0	1	0
P8	0	1	0	0	0	1	0	1
P9	0	0	1	0	0	1	1	0
P10	1	0	0	0	1	0	0	1

```
=== Tableau de Burt ===
```

	Bleu	Blanc	Vert	Léger	Lourd	Très lourd	Rond	Carré
Bleu	4.0	0.0	0.0	1.0	2.0	1.0	2.0	2.0
Blanc	0.0	3.0	0.0	2.0	0.0	1.0	1.0	2.0
Vert	0.0	0.0	3.0	1.0	0.0	2.0	2.0	1.0
Léger	1.0	2.0	1.0	4.0	0.0	0.0	3.0	1.0
Lourd	2.0	0.0	0.0	0.0	2.0	0.0	1.0	1.0
Très lourd	1.0	1.0	2.0	0.0	0.0	4.0	1.0	3.0
Rond	2.0	1.0	2.0	3.0	1.0	1.0	5.0	0.0
Carré	2.0	2.0	1.0	1.0	1.0	3.0	0.0	5.0

```
=== Tableau de contingence (Poids x Forme) ===
```

	Rond	Carré
Léger	3	1
Lourd	1	1
Très lourd	1	3

```
Somme totale = 10
```

Dans cette partie, nous avons construit le tableau disjonctif complet afin de transformer les variables qualitatives en variables binaires. Ensuite, nous avons calculé le tableau de Burt pour analyser les relations entre les différentes modalités. Enfin, nous avons vérifié un tableau de contingence pour confirmer la cohérence des résultats. Cette partie montre l'importance de la représentation matricielle dans l'analyse statistique.

Partie 3 :

```
import numpy as np
import pandas as pd
from scipy.stats import chi2_contingency, chi2

obs = np.array([
    [44, 156, 200],
    [6, 44, 50],
    [50, 200, 250]
])

# Étape 1 : Totaux marginaux
total_lignes = obs.sum(axis=1) # L_i
total_colonnes = obs.sum(axis=0) # C_j
n = obs.sum() # effectif total

print("=== Données observées ===")
print(pd.DataFrame(obs,
                    index=[f"Ligne {i+1}" for i in range(obs.shape[0])],
                    columns=[f"Colonne {j+1}" for j in range(obs.shape[1])]))
print(f"\nTotaux lignes : {total_lignes}")
print(f"\nTotaux colonnes : {total_colonnes}")
print(f"\nTotal général : {n}\n")

# Étape 2 : Effectifs théoriques sous indépendance
e = np.outer(total_lignes, total_colonnes) / n

print("=== Effectifs théoriques (e_ij) ===")
print(pd.DataFrame(e,
                    index=[f"Ligne {i+1}" for i in range(obs.shape[0])],
                    columns=[f"Colonne {j+1}" for j in range(obs.shape[1])]))

# Étape 3 : Calcul du khi-deux observé
chi2_obs = ((obs - e) ** 2 / e).sum()
print(f"\nKhi-deux observé (manuel) : {chi2_obs:.4f}")

# Vérification avec scipy
chi2_scipy, p_val, dof, expected = chi2_contingency(obs, correction=False)
print(f"\nKhi-deux (scipy) : {chi2_scipy:.4f}")
print(f"\np-valeur : {p_val:.4f}")
print(f"Degrés de liberté : {dof}")

# Étape 4 : Comparaison avec valeur critique
alpha = 0.05
chi2_critique = chi2.ppf(1 - alpha, dof)
print(f"\nValeur critique (α={alpha}) : {chi2_critique:.4f}")

if chi2_obs < chi2_critique:
    print("→ On accepte H0 : indépendance")
else:
    print("→ On rejette H0 : dépendance significative")

# Étape 5 : Conditions d'application
if np.all(e >= 5):
    print("Condition d'application respectée : tous les e_ij ≥ 5")
else:
    print("Attention : certains effectifs théoriques sont < 5")
    print("Cases concernées :", np.argwhere(e < 5))
```



```

=== Données observées ===
      Colonne 1  Colonne 2  Colonne 3
Ligne 1      44      156      200
Ligne 2       6       44       50
Ligne 3      50      200      250

Totaux lignes : [400 100 500]
Totaux colonnes : [100 400 500]
Total général : 1000

=== Effectifs théoriques (e_ij) ===
      Colonne 1  Colonne 2  Colonne 3
Ligne 1      40.0      160.0      200.0
Ligne 2      10.0       40.0       50.0
Ligne 3      50.0      200.0      250.0

Khi-deux observé (manuel) : 2.5000
Khi-deux (scipy) : 2.5000
p-valeur : 0.6446
Degrés de liberté : 4
Valeur critique ( $\alpha=0.05$ ) : 9.4877
→ On accepte  $H_0$  : indépendance
Condition d'application respectée : tous les  $e_{ij} \geq 5$ 

```

Le test du khi-deux permet de vérifier s'il existe une relation entre deux variables qualitatives en comparant les effectifs observés et théoriques. On calcule la statistique du khi-deux et on la compare à une valeur critique. Si la valeur calculée est inférieure à la valeur critique, les variables sont indépendantes, sinon elles sont dépendantes. Le test est valable si les effectifs théoriques sont ≥ 5 .