

Distances , similarités et corrélation

Définition générale d'une distance

Si tout le monde sait mesurer la distance d'un point A à un point B avec une règle, il faut savoir que ce n'est pas la seule manière de procéder. Pour être appelée « distance », un système de mesure doit répondre à trois critères essentiels.

Notons E l'ensemble dans lequel on veut mesurer notre distance, qui est une application

$$d : E \times E \rightarrow \mathbb{R}^+.$$

Définition générale d'une distance

Symétrie

La distance du point A au point B doit être la même que la distance du point B au point A. Autrement dit, **la distance n'a pas de sens.**

$$\forall (a, b) \in E^2, d(a, b) = d(b, a)$$

Définition générale d'une distance

Séparation

Cette propriété indique que si la distance de A à B vaut 0 alors, forcément, $A = B$ (et inversement).

Aucun point ne peut être infiniment proche de A sans être A.

$$\forall (a, b) \in E^2, d(a, b) = 0 \Leftrightarrow a = b$$

Définition générale d'une distance

Inégalité triangulaire

Aller de A à C est toujours plus court qu'aller de A à B puis de B à C.

Ainsi, **ajouter une étape à notre chemin augmente sa longueur** (ou au mieux la laisse inchangée)

$$\forall (a, b, c) \in E^3, d(a, c) \leq d(a, b) + d(b, c)$$

Distance de Manhattan (norme L1)

Nommée ainsi car elle sert à « mesurer » la distance parcourue par une voiture dans la ville de **Manhattan**, elle est la plus simple :
on additionne la distance parcourue sur chaque axe de l'espace
(dans un plan, ce sera (en valeur absolue) la coordonnée en x + la coordonnée en y).

Il y a donc beaucoup de chemins qui ont la même longueur !

$$\sum_{i=1}^n |x_i - y_i|.$$

Distance euclidienne (norme L2)

C'est la distance dont vous avez le plus l'habitude, celle de la règle, celle du « vol d'oiseau », la ligne droite. Sur notre schéma ci-dessus, c'est de mesurer la longueur du segment qui relie P1 à P2.

$$\sqrt{\sum_{i=1}^n (x_i - y_i)^2}.$$

Similarité cosinus

La **similarité cosinus** donne la similarité de deux vecteurs à n dimensions en déterminant le cosinus de leur angle. Ce score est fréquemment utilisé en fouille de textes.

Soit deux vecteurs A et B , le cosinus de leur angle θ s'obtient en prenant leur produit scalaire divisé par le produit de leurs normes :

$$\cos \theta = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}},$$

La valeur d'un cosinus, donc celle calculée ici pour $\cos \theta$, est comprise dans l'intervalle $[-1,1]$. La valeur de -1 indique des vecteurs opposés, la valeur de 0 des vecteurs indépendants (orthogonaux) et la valeur de 1 des vecteurs colinéaires de coefficient positif. Les valeurs intermédiaires permettent d'évaluer le degré de similarité

Document 1: Le Deep Learning peut être difficile

Document 2: Le Deep Learning peut être simple

Document 1: [1, 1, 1, 1, 1, 0]

Document 2: [1, 1, 1, 1, 0, 1]

similarité cosinus (CS) = (A · B) / (|| A || || B ||)

- **Calculez le produit scalaire entre A et B: $1,1 + 1,1 + 1,1 + 1,1 + 1,0 + 0,1 = 4$**
- **Calculez la grandeur du vecteur A: $\sqrt{1^2 + 1^2 + 1^2 + 1^2 + 1^2 + 0^2} = 2,2360679775$**
- **Calculez la grandeur du vecteur A: $\sqrt{1^2 + 1^2 + 1^2 + 1^2 + 0^2 + 1^2} = 2,2360679775$**
- **Calculer la similitude cosinus: $(4) / (2,2360679775 * 2,2360679775) = 0,80$ (80% de similitude entre les phrases des deux documents)**

Indice de Sørensen-Dice

L'**indice de Sørensen-Dice**, connu aussi sous les noms d'**indice de Sørensen**, **coefficient de Dice** et d'autres noms encore est un indicateur statistique qui mesure la similarité de deux échantillons. Il a été développé indépendamment par les botanistes Thorvald Sørensen et Lee Raymond Dice dans des articles publiés en 1948 et 1945 respectivement

$$s = \frac{2|X \cap Y|}{|X| + |Y|}$$

Indice de Sørensen-Dice

Contrairement à l'indice de Jaccard, la fonction

$$d = 1 - \frac{2|X \cap Y|}{|X| + |Y|}$$

n'est pas une distance puis qu'elle ne vérifie pas l'inégalité triangulaire. Le contre-exemple le plus simple est donné par les trois ensembles $\{a\}$, $\{b\}$, et $\{a,b\}$. La distance entre $\{a\}$ et $\{b\}$ est égale à 1, alors que la distance de ces deux ensembles au troisième, $\{a,b\}$, est $1/3$. Pour satisfaire l'inégalité triangulaire, la distance entre $\{a\}$ et $\{b\}$, qui est égale à 1, devrait être inférieure à la somme des deux autres distances, qui n'est que $2/3$.

Indice de Sørensen-Dice

Le coefficient peut aussi être utilisé comme une mesure de similarité entre chaînes de caractères. Étant donnés deux chaînes x et y , on peut calculer le coefficient comme suit

$$s = \frac{2n_t}{n_x + n_y}$$

Indice de Sørensen-Dice

n_t est le nombre de digrammes (formés de deux caractères consécutifs) communs aux deux chaînes, n_x est le nombre de digrammes dans x et n_y le nombre de digrammes dans y . Par exemple, pour calculer la similarité entre :

night et nacht

on calcule les digrammes de chaque mot :

ni,ig,gh,ht
na,ac,ch,ht

Chaque ensemble a quatre éléments, et leur intersection se réduit au seul élément

$$s = 2 \cdot 1 / (4 + 4) = 0.25.$$

L'indice de Jaccard

L'indice de Jaccard (ou coefficient de Jaccard), est le rapport entre le cardinal (la taille) de l'intersection des ensembles considérés et le cardinal de l'union des ensembles. Il permet d'évaluer la similarité entre les ensembles. Soit deux ensembles A et B, l'indice est :

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

L'indice de Jaccard

L'extension à n ensembles est triviale :

$$J(S_1, S_2, \dots, S_n) = \frac{|S_1 \cap S_2 \cap \dots \cap S_n|}{|S_1 \cup S_2 \cup \dots \cup S_n|}.$$

La distance de Jaccard mesure la dissimilarité entre les ensembles. Elle consiste simplement à soustraire l'indice de Jaccard à 1.

$$J_\delta(A, B) = 1 - J(A, B)$$

L'indice de Jaccard

L'indice de Jaccard est utile pour étudier la similarité entre des objets constitués d'attributs binaires.

Soit deux séquences A et B, chacune avec n attributs binaires. Chaque attribut peut être à 0 ou 1. On a ainsi :

$$A = (a_1, a_2, \dots, a_n)$$

$$B = (b_1, b_2, \dots, b_n) .$$

L'indice de Jaccard

L'indice de Jaccard devient :


$$J = \frac{M_{11}}{M_{01} + M_{10} + M_{11}}$$

		A	
		0	1
B	0	M_{00}	M_{10}
	1	M_{01}	M_{11}


CORRÉLATION

Si on fait la régression d'un indice relatif sur une variable indépendante, on se rend compte que le coefficient de corrélation varie entre -1 et +1. Une valeur négative signifie que les deux variables évoluent en sens inverse. Une valeur positive signifie qu'elles évoluent dans le même sens. Une valeur nulle signifie qu'il n'y a aucune relation entre les deux variables. On peut aussi dire que la corrélation mesure la force et le sens d'une relation linéaire entre deux variables.


Corrélation positive: $r = 0.93$



Corrélation négative: $r = -0.89$



Pas de corrélation: $r = 0$



CORRÉLATION

formule pour calculer le coefficient de corrélation de Pearson :

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$