

SVD et ACP

La décomposition en valeurs singulières (SVD=Singular Value Decomposition) est une méthode très générale de factorisation qui donne une nouvelle interprétation géométrique de n'importe quelle application linéaire $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Elle consiste à factoriser une matrice quelconque A ($m \times n$) en un produit,

$$A = U \Sigma V^T,$$

où

- 1) U est $m \times m$, orthogonale : $U^T U = U U^T = I_m$,
- 2) Σ est $m \times n$, **diagonale** dans le sens où $\Sigma_{ij} = 0$ si $i \neq j$. De plus, $\Sigma_{ij} \geq 0$.
- 3) V est $n \times n$, orthogonale : $V^T V = V V^T = I_n$.

Si $m = 7$ et $n = 4$, alors les 3 dernières lignes de Σ sont nulles :

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & \sigma_3 & 0 \\ 0 & 0 & 0 & \sigma_4 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Si $m = 3$, $n = 5$, alors les 2 dernières colonnes de Σ sont nulles :

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 & 0 \\ 0 & 0 & \sigma_3 & 0 & 0 \end{pmatrix}$$

La SVD décompose une matrice de données rectangulaire X (centrée) en trois matrices : $X = U\Sigma V^T$.

- Les vecteurs singuliers à droite (V) sont identiques aux vecteurs propres de la matrice de covariance $X^T X$, qui sont les axes (directions) principaux de l'ACP.
- Les valeurs singulières (Σ , diagonale) sont liées aux racines carrées des valeurs propres de la matrice de covariance. 

Image Compression with Singular Value Decomposition

$$\begin{array}{c}
 \text{A} \\
 \text{A(mxn)} \\
 \Sigma(\text{mxn}) \\
 \text{U} \\
 \text{U(mxm)} \\
 \text{V}^T \\
 \text{V(nxn)}
 \end{array}
 =
 \begin{array}{c}
 \text{U} \\
 \Sigma \\
 \text{V}^T
 \end{array}
 \cdot
 \begin{array}{c}
 \Sigma \\
 \text{V}^T
 \end{array}$$

$$\begin{array}{c}
 \text{A} \\
 \text{A(mxn)} \\
 \Sigma(\text{mxn}) \\
 \text{U} \\
 \text{U(mxm)} \\
 \text{V}^T \\
 \text{V(nxn)}
 \end{array}
 \approx
 \begin{array}{c}
 \text{U} \\
 \Sigma \\
 \text{V}^T
 \end{array}
 \cdot
 \begin{array}{c}
 \Sigma \\
 \text{V}^T
 \end{array}$$

$$\text{compressed size} = m \times k + k + k \times n = k \times (1 + m + n)$$




Figure 2: Number of Singular Values: $\{1, 2, 5, 10\} \cup \{15, 18, 24, 30\} \cup \{35, 60, 120, 680\}$




Figure 4: Number of Singular Values: $\{1, 250, 500, 550\}$ $\{575, 600, 625, 650\}$ $\{665, 678, 679, 680\}$

Only largest value



All but largest value



All values



Celebrate Pi Day



Celebrate Pi Day



Celebrate Pi Day



Celebrate Pi Day






Figure 9: Number of singular values per row: $\{1, 10, 25, 100\}$

```
import numpy as np
import matplotlib.pyplot as plt
from PIL import Image
```

```
# Load image (replace 'your_image.jpg' with your image file)
img = Image.open('your_image.jpg').convert('L') # Convert to grayscale
img_matrix = np.array(img)
```

```
# Perform SVD
U, s, Vt = np.linalg.svd(img_matrix, full_matrices=False)
```

```
# Choose number of singular values to keep (k) for compression
k = 50 # Example: keep 50 singular values
```

```
# Reconstruct compressed image
compressed_img_matrix = U[:, :k] @ np.diag(s[:k]) @ Vt[:k, :]
```