



Test Khi deux

SINFO S6



Le khi-deux est une statistique permettant de comparer les effectifs (fréquences) observés dans un échantillon avec des fréquences théoriques qui découlent des hypothèses statistiques.

Ajustement On suppose que la loi de probabilité de la variable aléatoire qualitative (ou quantitative avec peu de modalités) est connue et on veut vérifier c'est le cas. C'est le cas classique du lancer d'un dé. On suppose que chaque face a une probabilité identique et on veut vérifier si le dé est équilibré.



Homogénéité La variable aléatoire qualitative provient de k populations et on veut vérifier si la loi de probabilité est la même dans chaque population. On a donc k échantillons et on mesure la même caractéristique dans chacune d'elles. C'est le cas lorsqu'on veut savoir si la satisfaction (en quelques catégories) par rapport au service de transport en commun est semblable entre trois villes



Indépendance On mesure deux variables aléatoires qualitatives dans une population et on veut savoir si ces variables sont indépendantes c'est-à-dire si la connaissance d'une des v.a. peut influencer la loi de probabilité de l'autre. C'est le cas lorsqu'on veut vérifier si la satisfaction (en quelques catégories) par rapport au service de transport en commun est indépendant de la fréquence d'utilisation (en quelques catégories) de ces transports.



Égalité de proportions On est dans le contexte d'un test d'homogénéité mais la variable n'a que deux modalités que l'on peut qualifier de "succès" ou d'"échec" ET il n'y a que deux populations. Le fait de se demander si les deux populations ont la même distribution pour la variable mesurée c'est la même chose que de vérifier si les deux proportions de succès sont identiques.



L'idée des tests du khi deux est de comparer les valeurs observées et les valeurs moyennes qu'on observerait si l'hypothèse nulle est vraie. Considérons le cas d'un test visant à vérifier si un dé est équilibré c'est-à-dire si chacune des faces avait la même probabilité ($1/6$). Si on lance le dé 500 fois on devrait retrouver en moyenne $500 * 1/6 = \frac{250}{3} = 83.333$ fois la valeur "1" et 83.333 fois la valeur "2", etc. Supposons qu'on observe 90 valeur "1" sur les 500 lancers, 74 fois la valeur "2", 68 fois la valeur "3", 105 fois la valeur "4", 85 fois la valeur "5" et finalement $500 - (90 + 74 + 68 + 105 + 84) = 79$ fois la valeur "6". On cherche à établir si la différence entre les valeurs observées et les valeurs théoriques est importante ou simplement due à une variation aléatoire.



Posons n_i la valeur observée pour le nombre de fois que le "i" est sorti et T_i la valeur moyenne attendue. Si on fait simplement la différence entre les deux on obtient toujours 0 :

$$\sum (n_i - T_i) = \sum n_i - \sum T_i = n - n = 0$$

ce qui n'est pas particulièrement pratique. La statistique du khi deux utilise donc la différence au carré : $\sum (n_i - T_i)^2$. Or cette dernière façon de considérer les différences entre les valeurs qui donne un poids trop grand pour les petites valeurs de n_i : si on a une valeur théorique de 10 pour une modalité et une valeur observée de 5 alors la différence est la même que si on a une modalité avec une valeur théorique de 500 et une valeur



observée de 505. Il y a dans les deux cas une différence de 5 unités mais dans le premier cela correspond à une diminution de 50% et dans le deuxième à $5/500 * 100 = 1\%$. Pour éviter cette disproportion pour une modalité en particulier la statistique du khi deux est donnée par

$$\sum \frac{(n_i - T_i)^2}{T_i}$$

soit la différence relative. Dans tous les cas le principe est le même, seule la formulation des fréquences théoriques diffèrent selon les hypothèses.

Exemple 12.1 ★ Dans le but de vérifier si un dé est bien équilibré une machine "lance" le dé 1000 fois et on observe le nombre de points sur la face visible du dé. Les résultats sont donnés dans le tableau suivant :

Face	1	2	3	4	5	6
Observations	180	167	158	210	135	150

Faire un test au niveau 5% pour vérifier si le dé est équilibré.

Solution : Considérons la v.a. qui donne le nombre de points sur la face visible du dé, on veut confronter les hypothèses

$$H_0 : \pi_i = \frac{1}{6} \text{ pour chaque } i = 1, 2, \dots, 6$$

$$H_1 : \pi_i \neq \frac{1}{6} \text{ pour au moins un } i$$

Le test d'ajustement du khi-deux est de rejeter H_0 si

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - T_i)^2}{T_i} \geq \chi_{k-1;\alpha}^2$$

où $k = 6$ et $\alpha = 0.05$. On obtient

x_i	1	2	3	4	5	6
T_i	166.67	166.67	166.67	166.67	166.67	166.67

et ainsi les conditions d'application du test du khi-deux sont respectées.

On observe

$$\begin{aligned}\chi^2 &= \sum_{i=1}^k \frac{(n_i - T_i)^2}{T_i} \\ &= \frac{(180 - 166.67)^2}{166.67} + \frac{(167 - 166.67)^2}{166.67} + \dots \\ &= 20.468\end{aligned}$$

Or $\chi_{5;0.05}^2 = 11.07$ donc on rejette H_0 et on doit conclure avec un niveau de 5% que le dé n'est pas équilibré.

Exemple 12.2 ★★ Une étude sur la création d'entreprises vise à vérifier s'il y a une variabilité au cours de l'année. On observe 52 créations d'entreprises en 2007 et la distribution selon les saisons est la suivante :

Saison	Été	Automne	Hiver	Printemps
Créations	10	21	8	13

Faire un test au niveau 10% pour vérifier s'il y a une fluctuation dans l'année.

Solution : On veut confronter les hypothèses

$$H_0 : \pi_i = \frac{1}{4} \text{ pour } i = \text{"été"}, \text{"printemps"}, \text{"automne"}, \text{"hiver"}$$

$$H_1 : \pi_i \neq \frac{1}{4} \text{ pour au moins un } i$$

où π_i est la probabilité de création de l'entreprise à la saison i . Le test de niveau α est de rejeter H_0 si

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - T_i)^2}{T_i} \geq \chi_{k-1;\alpha}^2$$

k étant le nombre de saisons soit 4. On obtient

$$T_i = 52 * \frac{1}{4} = 13$$

pour chaque saison et ainsi les conditions d'application du test d'ajustement sont re-

spectées. Selon l'échantillon on observe

$$\begin{aligned}\chi^2 &= \frac{(10 - 13)^2}{13} + \frac{(21 - 13)^2}{13} + \\ &\quad \frac{(8 - 13)^2}{13} + \frac{(13 - 13)^2}{13} \\ &= 7.538\,5\end{aligned}$$

tandis que le point critique est

$$\chi_{k-1;\alpha}^2 = \chi_{3;0.1}^2 = 6.251\,4$$

On rejette alors H_0 au niveau 10% et on peut dire qu'il y a une différence selon les saisons.

Le test d'hypothèses pour confronter

H_0 : les v.a. sont indépendantes

H_1 : les v.a. sont dépendantes

est de rejeter H_0 si $\chi^2 \geq \chi^2_{(k-1)(m-1);\alpha}$, c'est-à-dire si la statistique est plus grande que le point critique de niveau α d'une loi khi deux à $(k - 1) (m - 1)$ degrés de liberté.

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^m \frac{(n_{ij} - T_{ij})^2}{T_{ij}}$$

où k est le nombre de modalités de X et m est le nombre de modalités de Y . Cette statistique est une mesure de la dépendance entre les v.a. X et Y .

Exemple 12.3 ★★ *Pour cibler la clientèle d'un nouveau produit de consommation, une entreprise fait un sondage auprès de 321 personnes. L'intérêt dans le produit est noté par "aucun intérêt", "un intérêt mineur" ou un "intérêt important". La situation familiale (au moins un enfant à charge : oui ou non) est notée également. On cherche à vérifier si l'intérêt dans le produit dépend de la situation familiale. Les résultats sont les suivants*

<i>Enfant</i>	<i>aucun</i>	<i>mineur</i>	<i>important</i>
<i>oui</i>	10	12	3
<i>non</i>	7	38	9

On a donc 79 personnes qui répondent. On veut vérifier s'il y a un lien entre les deux mesures au niveau 5%

Solution : On cherche à confronter les hypothèses H_0 : indépendance entre la v.a. famille et intérêt dans le produit et H_1 : dépendance entre la v.a. famille et intérêt dans le produit. Le niveau est fixé à 5% c'est-à-dire que la probabilité de dire qu'il y a dépendance étant donné qu'il y a indépendance entre ces deux variables est de 5%.

Le test est de rejeter H_0 si

$$\chi^2 = \sum \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} \geq \chi^2_{(m-1)(k-1); \alpha} = \chi^2_{2; 0.05} = 5.9915$$

On obtient le tableau de contingence suivant :

n_{ij}	<i>aucun</i>	<i>mineur</i>	<i>important</i>	
<i>oui</i>	10	12	3	25
<i>non</i>	7	38	9	54
	17	50	12	79

et le tableau des fréquences théoriques :

T_{ij}	aucun	mineur	important	
oui	5.400	15.823	3.800	25
non	11.620	34.177	8.203	54
	17	50	12	79

Il y a une cellule sur 6 qui contient une valeur attendue plus petite que 5. Cela correspond à $1/6 * 100 = 16.667\%$ des valeurs attendues, soit moins de 20%. Le test est donc valide.

La statistique observée est

$$\begin{aligned} \sum \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} &= \frac{(10 - 5.400)^2}{5.400} + \dots \\ &= 7.401 \end{aligned}$$

Exemple 12.4 ★★ *Un chercheur veut vérifier si deux universités ont un même barème*

pour l'attribution des cotes. Pour ce faire il choisit un échantillon de 21000 étudiants provenant des deux université et il regarde les cotes attribuées aux étudiants de 2001 :

<i>Cote</i>	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>
<i>Université I</i>	605	1400	1789	300	70
<i>Université II</i>	2014	4178	8032	2005	607

En fait, on cherche à vérifier si la répartition des cotes est dépendante des universités c'est-à-dire si les variables "université" et "cote" sont des v.a. indépendantes au niveau 5%

Solution : Les hypothèses statistiques sont

H_0 : les v.a. sont indépendantes

H_1 : les v.a. sont dépendantes

et le test du khi-deux est utilisé. Le test est de rejeter H_0 si

$$\chi^2 = \sum \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} \geq \chi^2_{(m-1)(k-1);\alpha} = \chi^2_{4;0.05} = 9.4877$$

On obtient le tableau de contingence suivant :

<i>Cote</i>	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>	
<i>Université I</i>	<i>605</i>	<i>1400</i>	<i>1789</i>	<i>300</i>	<i>70</i>	<i>4164</i>
<i>Université II</i>	<i>2014</i>	<i>4178</i>	<i>8032</i>	<i>2005</i>	<i>607</i>	<i>16836</i>
	<i>2619</i>	<i>5578</i>	<i>9821</i>	<i>2305</i>	<i>677</i>	<i>21000</i>

Les fréquences théoriques sont données par :

<i>Cote</i>	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>	<i>E</i>	
<i>Université I</i>	<i>519.310</i>	<i>1106.038</i>	<i>1947.364</i>	<i>457.049</i>	<i>134.239</i>	<i>4164</i>
<i>Université II</i>	<i>2099.690</i>	<i>4471.962</i>	<i>7873.636</i>	<i>1847.951</i>	<i>542.761</i>	<i>16836</i>
	<i>2619</i>	<i>5578</i>	<i>9821</i>	<i>2305</i>	<i>677</i>	<i>21000</i>

La statistique observée est

$$\begin{aligned} \sum \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} &= \frac{(605 - 519.310)^2}{519.310} + \dots \\ &= 236.808 \end{aligned}$$

On rejette donc H_0 au niveau 5% et on peut dire qu'il y a dépendance.

Python et Khi_deux

Pour effectuer un **test du Khi-deux** (χ^2) en Python, la bibliothèque de référence est SciPy, plus précisément le module `scipy.stats`.  DataCamp +3

Il existe deux types de tests courants :

1. Test d'indépendance (Lien entre deux variables)

Ce test vérifie si deux variables qualitatives sont indépendantes à l'aide d'un **tableau de contingence**.  YouTube +1

python

```
from scipy.stats import chi2_contingency

# Exemple : Tableau croisant Le Genre (lignes) et La Préférence (colonnes)
# [[Hommes_A, Hommes_B], [Femmes_A, Femmes_B]]
data = [[20, 30], [35, 15]]

stat, p, dof, expected = chi2_contingency(data)

print(f"Statistique Khi2 : {stat:.4f}")
print(f"P-valeur : {p:.4f}") # Si  $p < 0.05$ , Les variables sont dépendantes
```

- **Fonction :** `chi2_contingency()` .
- **Interprétation :** Si la **p-valeur** est inférieure à votre seuil (souvent 0,05), on rejette l'hypothèse nulle (H_0) d'indépendance.  Joseph Salmon +1



python

```
from scipy.stats import chisquare

# Fréquences observées vs attendues
f_obs = [16, 18, 16, 14, 12, 12]
f_exp = [14.6, 14.6, 14.6, 14.6, 14.6, 14.6]

stat, p = chisquare(f_obs, f_exp)
print(f"P-valeur : {p:.4f}")
```

Caractéristique **chisquare****chi2_contingency****Objectif**

Adéquation à une loi (1 variable)

Indépendance (2 variables)

Input


Vecteur 1D (fréquences)

Matrice 2D (tableau croisé)

Fréquences attendues

À fournir manuellement

Calculées automatiquement



Pour générer un tableau de contingence avec [Pandas](#), on utilise principalement la fonction `pd.crosstab()`. Elle permet de croiser deux colonnes d'un DataFrame pour obtenir les fréquences d'apparition de chaque combinaison.

 ApX Machine Learning +3

python

```
import pandas as pd
```

```
# 1. Créer ou charger vos données
```

```
df = pd.DataFrame({  
    'Genre': ['H', 'F', 'H', 'F', 'H', 'F', 'H', 'H'],  
    'Achat': ['Oui', 'Non', 'Oui', 'Oui', 'Non', 'Non', 'Oui', 'Oui']  
})
```

```
# 2. Générer Le tableau de contingence
```

```
table = pd.crosstab(df['Genre'], df['Achat'])
```

```
print(table)
```

TABLE DU CHI-DEUX : $\chi^2(n)$ 

n ^P	0.90	0.80	0.70	0.50	0.30	0.20	0.10	0.05	0.02	0.01
1	0,0158	0,0642	0,148	0,455	1,074	1,642	2,706	3,841	5,412	6,635
2	0,211	0,446	0,713	1,386	2,408	3,219	4,605	5,991	7,824	9,210
3	0,584	1,005	1,424	2,366	3,665	4,642	6,251	7,815	9,837	11,341
4	1,064	1,649	2,195	3,357	4,878	5,989	7,779	9,488	11,668	13,277
5	1,610	2,343	3,000	4,351	6,064	7,289	9,236	11,070	13,388	15,086
6	2,204	3,070	3,828	5,348	7,231	8,558	10,645	12,592	15,033	16,812
7	2,833	3,822	4,671	6,346	8,383	9,803	12,017	14,067	16,622	18,475
8	3,490	4,594	5,527	7,344	9,524	11,030	13,362	15,507	18,168	20,090
9	4,168	5,380	6,393	8,343	10,656	12,242	14,684	16,919	19,679	21,666
10	4,865	6,179	7,267	9,342	11,781	13,442	15,987	18,307	21,161	23,209
11	5,578	6,989	8,148	10,341	12,899	14,631	17,275	19,675	22,618	24,725
12	6,304	7,807	9,034	11,340	14,011	15,812	18,549	21,026	24,054	26,217
13	7,042	8,634	9,926	12,340	15,119	16,985	19,812	22,362	25,472	27,688
14	7,790	9,467	10,821	13,339	16,222	18,151	21,064	23,685	26,873	29,141
15	8,547	10,307	11,721	14,339	17,322	19,311	22,307	24,996	28,259	30,578
16	9,312	11,152	12,624	15,338	18,418	20,465	23,542	26,296	29,633	32,000
17	10,085	12,002	13,531	16,338	19,511	21,615	24,769	27,587	30,995	33,409
18	10,865	12,857	14,440	17,338	20,601	22,760	25,989	28,869	32,346	34,805
19	11,651	13,716	15,352	18,338	21,689	23,900	27,204	30,144	33,687	36,191
20	12,443	14,578	16,266	19,337	22,775	25,038	28,412	31,410	35,020	37,566
21	13,240	15,445	17,182	20,337	23,858	26,171	29,615	32,671	36,343	38,932
22	14,041	16,314	18,101	21,337	24,939	27,301	30,813	33,924	37,659	40,289
23	14,848	17,187	19,021	22,337	26,018	28,429	32,007	35,172	38,968	41,638
24	15,659	18,062	19,943	23,337	27,096	29,553	33,196	36,415	40,270	42,980
25	16,473	18,940	20,867	24,337	28,172	30,675	34,382	37,652	41,566	44,314
26	17,292	19,820	21,792	25,336	29,246	31,795	35,563	38,885	42,856	45,642
27	18,114	20,703	22,719	26,336	30,319	32,912	36,741	40,113	44,140	46,963
28	18,939	21,588	23,647	27,336	31,391	34,027	37,916	41,337	45,419	48,278
29	19,768	22,475	24,577	28,336	32,461	35,139	39,087	42,557	46,693	49,588